

ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA EN SISTEMAS
RECUPERACIÓN DE INFORMACIÓN

Integrantes: Erick Carcelen, Kenneth Yar, Martin Zambonino

Fecha: 30/05/2026

INFORME TÉCNICO

Proyecto de 1er Bimestre - Sistema de Recuperación de Información

Contenido

1. Descripción del corpus.....	1
2. Decisiones de diseño	2
2.1. Preprocesamiento	2
2.2. Índice invertido	2
2.3. Modelos clásicos	2
2.4. Recuperación semántica	2
2.5. Interfaz CLI.....	2
3. Ejemplos de consultas y resultados	2
4. Evaluación y comparación de modelos	3
4.1. Metodología de evaluación	3
4.2. Resultados por consulta.....	3
4.3. Rendimiento global del sistema	4
4.4. Comparación de modelos	4
4.4.1. Consultas con términos específicos	4
4.4.2. Comportamiento de Jaccard	4
4.4.3. Casos donde mejora la recuperación semántica	5
4.4.4. Casos donde empeora la recuperación semántica.....	5
5. Conclusiones.....	5
 Table 1. Resultados recuperados para “japan trade”	2
Table 2. Métricas de evaluación por consulta	3
Table 3. MAP global por modelo.....	4

1. Descripción del corpus

Para el proyecto se trabajó con el corpus Reuters-21578 en la partición ModApte de entrenamiento. En el archivo ModApte_train.csv hay 9.603 noticias de tipo financiero y económico. Para este sistema se usaron principalmente las columnas title, text y topics. La columna title sirve para mostrar el nombre del documento recuperado, text se usa como contenido

para indexar y topics se usa en la evaluación para saber qué documentos son relevantes para cada consulta de prueba.

Antes de construir los modelos se controlaron algunos valores nulos. Cuando un documento no tenía título se reemplazó por “No Title”, y cuando no tenía texto se usó una cadena vacía. Esto se hizo para evitar errores al tokenizar, vectorizar o generar embeddings.

2. Decisiones de diseño

2.1. Preprocesamiento

El preprocesamiento se mantuvo simple: normalización a minúsculas, tokenización con la expresión regular `\b\w+\b` y eliminación de stopwords en inglés con `ENGLISH_STOP_WORDS` de `scikit-learn`. No se aplicó stemming ni lematización para mantener una implementación directa y fácil de revisar.

2.2. Índice invertido

El índice invertido usa la estructura `dict[str, dict[int, int]]`, donde cada término apunta a los documentos donde aparece y a su frecuencia. Esta estructura se usa en Jaccard y BM25 para recuperar documentos candidatos antes de calcular el ranking.

2.3. Modelos clásicos

Jaccard usa conjuntos de términos y la fórmula $|D \cap Q| / |D \cup Q|$. TF-IDF usa `TfidfVectorizer` y similitud coseno. BM25 se implementó con $k1=1.5$ y $b=0.75$, considerando frecuencia de término, IDF y longitud documental.

2.4. Recuperación semántica

La recuperación semántica usa `all-MiniLM-L6-v2` de `sentence-transformers`. Los embeddings se almacenan en FAISS con `IndexFlatIP` y se normalizan con L2 para usar producto interno como similitud coseno.

2.5. Interfaz CLI

La CLI funciona como buscador: el usuario escribe una consulta libre y el sistema muestra resultados de Jaccard, TF-IDF, BM25 y Embeddings. También incluye “**:ayuda, :eval, :top N y :salir**”

3. Ejemplos de consultas y resultados

Como ejemplo se usó la consulta “japan trade” con top 3 por modelo. Se escogió esta consulta porque permite ver diferencias claras entre recuperación por términos y recuperación semántica.

Table 1. Resultados recuperados para “japan trade”

Modelo	Documento recuperado	Score
Jaccard	JAPAN BUYS 5,000 TONNES CANADIAN RAPESEED	0.1250
Jaccard	CORRECTION - SENIOR U.S. OFFICIAL... TRADE ROW	0.0800
Jaccard	JAPAN CENTRAL BANK INTERVENES IN TOKYO AFTERNOON	0.0625
TF-IDF	ECONOMIC SPOTLIGHT - U.S. CONGRESS RAPS JAPAN	0.5104
TF-IDF	EUROPE ON SIDELINES IN U.S-JAPAN MICROCHIP ROW	0.5070
TF-IDF	BANK OF JAPAN CALLS FOR LONG-TERM EFFORTS ON TRADE	0.4460
BM25	S.KOREA SAYS JAPAN COMPLAINS TO GATT ON TRADE PLAN	10.2338

BM25	BANK OF JAPAN CALLS FOR LONG-TERM EFFORTS ON TRADE	9.9651
BM25	U.S.-JAPAN NOT IN TRADE WAR, YEUTTER SAYS	9.8927
Embeddings	JAPAN WILL ASK COMPANIES TO BOOST IMPORTS	0.6335
Embeddings	U.S. OFFICIAL TO VISIT JAPAN AS TRADE ROW GROWS	0.6179
Embeddings	CANADA, JAPAN TRADING FIRM AGREE TO BOOST TIES	0.6161

En esta consulta se observa que Jaccard recupera documentos con términos compartidos, pero no siempre los más específicos sobre comercio. TF-IDF y BM25 recuperan documentos más relacionados con el conflicto comercial de Japón. En cambio, Embeddings recupera documentos que tratan sobre relaciones comerciales o importaciones, aunque no necesariamente tengan la misma combinación exacta de palabras.

4. Evaluación y comparación de modelos

4.1. Metodología de evaluación

Para La evaluación se realizó con cinco consultas basadas en categorías reales del corpus: coffee, gold, acq, earn y crude. Los qrels se obtuvieron desde la columna topics: un documento se consideró relevante si contenía la categoría correspondiente. La evaluación se limitó al Top-10 de cada modelo. Se calcularon Precision, Recall,

Precision mide la proporción de documentos relevantes en el Top-10. Recall mide qué parte del total de relevantes fue recuperada. AP promedia las precisiones en las posiciones donde aparece un documento relevante. MAP promedia el AP de todas las consultas.

4.2. Resultados por consulta

Los resultados muestran que cada modelo se comporta diferente según el tipo de consulta. En algunas consultas, los modelos basados en términos funcionaron mejor. En otras, el modelo semántico logró recuperar documentos que los modelos léxicos no encontraron.

Table 2. Métricas de evaluación por consulta

Consulta	Total relevantes	Modelo	Precision	Recall	AP
coffee	107	TF-IDF	1.00	0.0935	0.0935
coffee	107	Jaccard	0.90	0.0841	0.0821
coffee	107	BM25	1.00	0.0935	0.0935
coffee	107	Semántico	1.00	0.0935	0.0935
gold	87	TF-IDF	1.00	0.1149	0.1149
gold	87	Jaccard	0.50	0.0575	0.0420
gold	87	BM25	1.00	0.1149	0.1149
gold	87	Semántico	0.00	0.0000	0.0000
acq	1626	TF-IDF / BM25 / Jaccard	0.00	0.0000	0.0000
acq	1626	Semántico	0.40	0.0025	0.0021
earn	2827	TF-IDF / BM25	0.50	0.0018	0.0012
earn	2827	Jaccard	0.30	0.0011	0.0006

earn	2827	Semántico	1.00	0.0035	0.0035
crude	366	TF-IDF	1.00	0.0273	0.0273
crude	366	Jaccard	0.90	0.0246	0.0233
crude	366	BM25	0.90	0.0246	0.0237
crude	366	Semántico	0.80	0.0219	0.0200

4.3. Rendimiento global del sistema

Para comparar el rendimiento general de los modelos se calculó el MAP, que significa Mean Average Precision. Esta métrica promedia el Average Precision obtenido en las cinco consultas evaluadas.

Table 3. MAP global por modelo

Modelo	MAP
TF-IDF	0.0474
BM25	0.0466
Jaccard	0.0296
Semántico	0.0238

A primera vista, los valores de Recall y MAP parecen bajos, pero esto se debe interpretar considerando que la evaluación solo toma los primeros 10 resultados. Algunas categorías tienen muchos documentos relevantes. Por ejemplo, earn tiene 2.827 documentos relevantes en el corpus. Entonces, aunque el sistema recuperara 10 documentos correctos, el máximo recall posible en Top-10 sería:

$$10 / 2827 = 0.0035$$

Por esta razón, en esta evaluación la Precision at 10 ayuda bastante a entender la calidad de los primeros resultados, ya que muestra cuántos de los documentos que el usuario vería primero son realmente relevantes.

4.4. Comparación de modelos

4.4.1. Consultas con términos específicos

Los modelos basados en términos, principalmente TF-IDF y BM25, tuvieron mejores resultados en consultas específicas como coffee, gold y crude. En estos casos, las palabras consultadas aparecen de forma directa en los documentos relevantes, por lo que los modelos léxicos pueden identificarlas con mayor facilidad.

En estas consultas, TF-IDF y BM25 alcanzaron valores de precisión altos, cercanos o iguales a 1.00. Esto muestra que ambos modelos son buenos cuando la consulta contiene palabras clave claras y presentes en el texto.

BM25 y TF-IDF tuvieron resultados parecidos porque los dos dependen de coincidencias de términos. La diferencia es que BM25 también toma en cuenta la longitud del documento y controla mejor el efecto de repetir muchas veces una palabra.

4.4.2. Comportamiento de Jaccard

El modelo Jaccard fue el menos fuerte entre los modelos basados en términos. Su MAP fue 0.0296, menor que TF-IDF y BM25.

Esto se explica porque Jaccard trabaja de forma binaria. Es decir, solo considera si un término aparece o no aparece en el documento. No toma en cuenta cuántas veces aparece ni qué tan

importante es ese término dentro del corpus. Por eso, aunque es un modelo fácil de entender, no siempre ordena los documentos de la mejor manera.

En consultas como gold, Jaccard obtuvo menor precisión que TF-IDF y BM25. Esto muestra que la coincidencia simple de términos no siempre es suficiente para obtener un buen ranking.

4.4.3. Casos donde mejora la recuperación semántica

La recuperación semántica con Embeddings + FAISS fue útil en consultas donde la coincidencia exacta de palabras no era suficiente. El caso más claro fue acq.

En la consulta acq, los modelos TF-IDF, BM25 y Jaccard obtuvieron Precision = 0.00. En cambio, el modelo semántico logró recuperar documentos relevantes con una precisión de 0.40.

Esto indica que el modelo semántico pudo recuperar documentos relacionados con adquisiciones, aunque la palabra exacta acq no apareciera de forma directa en el texto. En este tipo de caso, los embeddings ayudan porque trabajan con relación de significado, no solo con coincidencia literal de caracteres.

Algo parecido ocurrió con earn. En esta consulta, el modelo semántico alcanzó Precision = 1.00, mientras que TF-IDF y BM25 quedaron en 0.50. Esto muestra que la recuperación semántica puede funcionar mejor cuando el tema se expresa con palabras relacionadas, como ganancias, ingresos o resultados financieros.

4.4.4. Casos donde empeora la recuperación semántica

Aunque el modelo semántico tuvo buenos resultados en algunos casos, también presentó fallos. El ejemplo más claro fue la consulta gold.

En gold, TF-IDF y BM25 obtuvieron Precision = 1.00, mientras que el modelo semántico obtuvo Precision = 0.00. Esto muestra que los embeddings no siempre superan a los modelos clásicos.

Una posible razón es que gold es una consulta muy corta y sin contexto adicional. Al tener solo una palabra, el modelo puede recuperar documentos relacionados con otros sentidos de esa palabra y no necesariamente con el sentido financiero esperado dentro del corpus Reuters. Por eso, en consultas cortas y específicas, los modelos léxicos pueden ser más seguros.

5. Conclusiones

Los resultados muestran que no existe un modelo que sea mejor en todos los casos. Cada modelo tiene ventajas y limitaciones según el tipo de consulta.

En consultas con términos concretos, como coffee, gold o crude, los modelos léxicos como TF-IDF y BM25 tuvieron mejor comportamiento. Esto ocurre porque esas palabras aparecen directamente en los documentos relevantes, y estos modelos están diseñados para aprovechar esa coincidencia de términos.

Jaccard funcionó como un modelo base, pero tuvo menor rendimiento porque solo usa presencia o ausencia de términos. No considera frecuencia, importancia del término ni longitud del documento.

El modelo semántico tuvo el MAP global más bajo, pero aun así mostró resultados importantes en consultas como acq y earn. En estos casos, la coincidencia exacta de términos no fue suficiente, y los embeddings permitieron recuperar documentos relacionados por significado.

En general, los resultados indican que TF-IDF y BM25 son opciones más estables para consultas con palabras clave claras. La recuperación semántica puede aportar valor cuando la consulta es más conceptual o cuando los documentos usan vocabulario diferente, pero también puede fallar si la consulta es muy corta o ambigua.